

ระบบบริหารจัดการจราจรแบบปรับตัวผ่านการเรียนรู้เชิงเสริมกำลัง
Adaptive traffic management system via reinforcement learning

นายสุทธินันท์ สาระวิโรจน์¹, นางสาวสุพิชญา ปรางค์เจริญ¹, นางสาวปัทมาพร ทองเปลว¹

S. Sarawirot¹, S. Prangcharoen¹, P. Thongplaew¹

และ ผศ.ดร.ฐิตาภรณ์ กนกรัตน^{2*}

and T. Ganokratanaa^{2*}

¹นักศึกษาสาขาวิชาวิทยาการคอมพิวเตอร์ประยุกต์ คณะวิทยาศาสตร์มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี เขตทุ่งครุ
กรุงเทพมหานคร

¹Undergraduate student of Applied Computer Science, Faculty of Science, King Mongkut's University of
Technology Thonburi Thung Khru, Bangkok Thailand

²ผศ.ดร., คณะวิทยาศาสตร์ มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี เขตทุ่งครุ กรุงเทพมหานคร

²Asst.Prof.Dr., Faculty of Science, King Mongkut's University of Technology Thonburi Thung Khru, Bangkok
Thailand

* E-mail:

บทคัดย่อ

ปัญหาการจราจรติดขัดในเขตเมืองเป็นปัญหาสำคัญที่ส่งผลกระทบต่อทั้งเศรษฐกิจและคุณภาพชีวิต โดยส่วนหนึ่งเกิดจากความไม่มีประสิทธิภาพของระบบควบคุมสัญญาณไฟจราจรแบบตั้งเวลาตายตัว (Rule-Based) โครงการนี้จึงมีวัตถุประสงค์เพื่อพัฒนาระบบ "TraffixFlow" ซึ่งเป็นแพลตฟอร์มควบคุมสัญญาณไฟจราจรแบบปรับตัวได้ (Adaptive Traffic Signal Control) ที่บูรณาการการทำงานร่วมกันระหว่างเทคโนโลยีคอมพิวเตอร์วิทัศน์ (Computer Vision) และการเรียนรู้แบบเสริมกำลังเชิงลึก (Deep Reinforcement Learning) ระบบที่พัฒนาขึ้นสามารถประมวลผลข้อมูลจราจรในรูปแบบไฮบริด ทั้งจากการรับภาพกล้องวิดีโอแบบเรียลไทม์เพื่อตรวจจับและติดตามยานพาหนะด้วยแบบจำลอง YOLOv12 ร่วมกับ Optical Flow และการดึงข้อมูลจากสภาพแวดล้อมจำลองโครงข่ายการจราจรขนาด 14 ทางแยกผ่านโปรแกรม SUMO (Simulation of Urban MObility) ในด้านการควบคุมสัญญาณไฟ ได้ทำการเปรียบเทียบประสิทธิภาพอัลกอริทึมปัญญาประดิษฐ์ 3 รูปแบบ

ได้แก่ PPO (Proximal Policy Optimization), DQN (Deep Q-Network) และ A2C (Advantage Actor-Critic) โดยใช้ระบบตั้งเวลาตายตัว (Fixed time) เป็นเส้นฐาน (Baseline) ในการประเมินผล ดัชนีชี้วัดที่ใช้ประกอบด้วย ปริมาณการระบายรถสะสมเฉลี่ย (Average Throughput) เวลารอคอยสะสมเฉลี่ย (Average Wait Time) และ คะแนนผลตอบแทนเฉลี่ย (Average Reward) ผลการทดลองพบว่า อัลกอริทึม A2C มีประสิทธิภาพสูงที่สุดในทุก ดัชนีชี้วัด โดยสามารถทำคะแนนผลตอบแทนเฉลี่ยได้สูงสุดที่ 402.62 และเมื่อเปรียบเทียบกับระบบตั้งเวลาตายตัว พบว่าโมเดล A2C สามารถเพิ่มปริมาณการระบายรถสะสมได้ 3,749 คัน (เพิ่มขึ้นร้อยละ 12.75) และสามารถลด เวลารอคอยสะสมเฉลี่ยลงเหลือ 8,698 วินาที (ลดลงร้อยละ 36.36) จากผลการวิจัยสรุปได้ว่า ระบบ TraffixFlow และการประยุกต์ใช้อัลกอริทึม A2C มีความเหมาะสมอย่างยิ่งในการนำมาจัดการระบบสัญญาณไฟจราจรใน โครงข่ายที่มีความซับซ้อน เนื่องจากสามารถตรวจจับและตอบสนองต่อปริมาณรถที่เปลี่ยนแปลงแบบพลวัตได้ อย่างมีประสิทธิภาพ อย่างไรก็ตาม แบบจำลองที่ฝึกสอนในโครงงานนี้มีความเชี่ยวชาญเฉพาะเจาะจงกับลักษณะ ทางกายภาพและรูปแบบการจราจรของโครงข่ายถนนเขตปทุมวันเป็นหลัก หากต้องการนำระบบไปประยุกต์ใช้กับ พื้นที่อื่น อาจจำเป็นต้องมีการนำแบบจำลองไปฝึกสอนเพิ่มเติม (Fine-tuning) หรือปรับค่าพารามิเตอร์เพื่อให้ สอดคล้องกับบริบทของพื้นที่นั้น ๆ ซึ่งสามารถนำไปต่อยอดเป็นระบบจราจรอัจฉริยะในสภาพแวดล้อมจริงได้อย่าง ยั่งยืนในอนาคต

คำสำคัญ: การควบคุมสัญญาณไฟจราจร, คอมพิวเตอร์วิทัศน์, YOLOv12, การเรียนรู้แบบเสริมกำลังเชิงลึก, SUMO, A2C

Abstract

Traffic congestion in urban areas is a critical issue that significantly impacts both the economy and quality of life. This problem is partially caused by the inefficiency of conventional, fixed-time (rule-based) traffic signal control systems. Therefore, this project aims to develop "TraffixFlow," an Adaptive Traffic Signal Control platform that integrates Computer Vision and Deep Reinforcement Learning technologies. The developed system is capable of processing traffic data in a hybrid architecture. It utilizes real-time video feeds for vehicle detection and tracking via the YOLOv12 model combined with Optical Flow, while also extracting data from a simulated 10-intersection traffic network environment using SUMO (Simulation of Urban MObility). Regarding traffic signal control, the performance of three artificial intelligence algorithms—PPO (Proximal Policy Optimization), DQN (Deep Q-Network), and A2C (Advantage Actor-Critic)—was evaluated and compared against a rule-based baseline

system. The evaluation metrics consisted of Average Throughput, Average Wait Time, and Average Reward. The experimental results revealed that the A2C algorithm achieved the highest performance across all metrics, attaining a maximum average reward of 402.62. Compared to the rule-based system, the A2C model increased the cumulative throughput by 3,749 vehicles (a 12.75% increase) and reduced the cumulative average wait time to 8,698 seconds (a 36.36% decrease). In conclusion, the TraffixFlow system and the application of the A2C algorithm are highly suitable for managing traffic signals in complex networks due to their capability to efficiently detect and dynamically respond to fluctuating traffic volumes. However, the models trained in this project are specifically specialized to the physical characteristics and traffic patterns of the Pathum Wan district road network. Applying the system to other geographical locations may require further fine-tuning of the models or parameter adjustments to align with the specific context of those areas. This research can serve as a foundation for further development into a sustainable, real-world intelligent traffic system in the future.

Keywords: Traffic Signal Control, Computer Vision, YOLOv12, Deep Reinforcement Learning, SUMO, A2C

1. บทนำ

1.1 ที่มาและความสำคัญของโครงการ

ในปัจจุบัน การขยายตัวของความเป็นเมือง (Urbanization) และการเติบโตทางเศรษฐกิจส่งผลให้ความต้องการในการเดินทางและจำนวนยานพาหนะบนโครงข่ายถนนเพิ่มสูงขึ้นอย่างก้าวกระโดด ในขณะที่การพัฒนาโครงสร้างพื้นฐานทางถนน เช่น การขยายช่องจราจร หรือการสร้างเส้นทางใหม่ ไม่สามารถดำเนินการให้สอดคล้องกับปริมาณยานพาหนะที่เพิ่มขึ้นได้อย่างทันทั่วถึง ปัญหาการจราจรติดขัดในเขตเมืองจึงกลายเป็นความท้าทายระดับโลกที่สร้างผลกระทบเชิงลบอย่างรุนแรงในหลายมิติ ทั้งในด้านเศรษฐกิจที่ต้องสูญเสียมูลค่าจากความล่าช้าในการเดินทาง และด้านสิ่งแวดล้อมจากการเผาผลาญเชื้อเพลิงโดยไม่จำเป็นและ

การปล่อยมลพิษทางอากาศที่เพิ่มสูงขึ้น ดังนั้น การมุ่งเน้นไปที่การเพิ่มประสิทธิภาพของโครงสร้างพื้นฐานเดิมที่มีอยู่ ผ่านระบบการจัดการจราจรอัจฉริยะ (Intelligent Transportation Systems: ITS) จึงเป็นทางออกที่มีความยั่งยืนและเป็นไปได้มากที่สุดในยุคปัจจุบัน

หัวใจสำคัญของการจัดการจราจรในเขตเมืองคือ "ระบบควบคุมสัญญาณไฟจราจร" โดยเฉพาะบริเวณทางแยกซึ่งเป็นจุดวิกฤตที่ทำให้เกิดการสะสมของปริมาณรถ อย่างไรก็ตาม ระบบควบคุมสัญญาณไฟจราจรที่ใช้กันอยู่อย่างแพร่หลายในปัจจุบัน ส่วนใหญ่ยังคงพึ่งพาแบบตั้งเวลาตายตัว (Fixed-time Control) ซึ่งทำงานตามตารางเวลาที่ถูกกำหนดไว้ล่วงหน้าจากข้อมูลสถิติในอดีต แม้จะมีการพัฒนาระบบควบคุมแบบกึ่งตอบสนอง (Actuated Control) ที่อาศัยเซนเซอร์มาร่วมใช้งาน แต่ระบบเหล่านี้ก็ยังมีข้อจำกัดอย่างมากในการปรับตัวให้เข้ากับพลวัตของการจราจร (Dynamic Traffic Flow) ที่เปลี่ยนแปลงตลอดเวลาแบบเรียลไทม์ ความไม่ยืดหยุ่นนี้ส่งผลให้เกิดปัญหา "การให้สัญญาณไฟเขียวอย่างสูญเปล่า" (Wasteful Green Light Problem) ซึ่งเป็นสภาวะที่ระบบยังคงปล่อยสัญญาณไฟเขียวให้กับช่องจราจรที่ไม่มีรถยนต์เหลืออยู่ หรือปล่อยไฟเขียวในขณะที่แยกถัดไปมีรถสะสมจนล้น (Spillback Effect) สภาวะเหล่านี้ส่งผลให้เวลารอคอยเฉลี่ย (Average Waiting Time) และความยาวของแถวคอย (Queue Length) เพิ่มขึ้นอย่างหลีกเลี่ยงไม่ได้ [5], [13] เพื่อก้าวข้ามขีดจำกัดของระบบควบคุมแบบดั้งเดิม เทคโนโลยีทางด้านปัญญาประดิษฐ์ (Artificial Intelligence: AI) จึงได้ถูกนำมาประยุกต์ใช้อย่างกว้างขวาง โดยเฉพาะเทคนิค "การเรียนรู้แบบเสริมกำลังเชิงลึก" (Deep Reinforcement Learning: DRL) ซึ่งมีความโดดเด่นในการแก้ปัญหาการตัดสินใจ กลไกของ DRL ช่วยให้ระบบตัวแทน (Agent) สามารถเรียนรู้กลยุทธ์การควบคุมสัญญาณไฟที่เหมาะสมที่สุดได้ด้วยตนเองผ่านการลองผิดลองถูกและโต้ตอบกับสภาพแวดล้อมของการจราจรโดยตรง โดยไม่ต้องพึ่งพาการสร้างแบบจำลองทางคณิตศาสตร์ที่ซับซ้อนและตายตัว อัลกอริทึม DRL ขั้นสูง เช่น PPO, DQN และ A2C ได้รับการพิสูจน์ผ่านงานวิจัยหลายชิ้นว่าสามารถปรับตัวเข้ากับสภาพผันผวนของปริมาณรถยนต์ และสามารถลดความยาวของแถวคอย รวมถึงเวลารอคอยสะสมได้อย่างมีนัยสำคัญ เมื่อเปรียบเทียบกับระบบตั้งเวลาตายตัว [6], [7], [8]

อย่างไรก็ตาม ประสิทธิภาพของอัลกอริทึม DRL จะเกิดขึ้นได้สูงสุดก็ต่อเมื่อระบบได้รับข้อมูลสภาพแวดล้อมที่มีความถูกต้องและเป็นปัจจุบัน ในอดีตการตรวจนับยานพาหนะมักอาศัยเซนเซอร์แบบฝังใต้พื้นถนน ซึ่งมีข้อจำกัดด้านพื้นที่การตรวจนับและค่าใช้จ่าย โครงการนี้จึงบูรณาการเทคโนโลยีคอมพิวเตอร์วิทัศน์ (Computer Vision) โดยนำโมเดลโครงข่ายประสาทเทียมที่สามารถตรวจนับวัตถุได้อย่างแม่นยำอย่าง YOLO (You Only Look Once) มาร่วมใช้งาน [3], [9] การใช้ภาพจากกล้องวิดีโอทำให้ระบบสามารถมองเห็น

และวิเคราะห์ข้อมูลเชิงลึกได้แบบเรียลไทม์ ด้วยเหตุนี้ โครงการนี้จึงมีวัตถุประสงค์เพื่อพัฒนาระบบ "TraffixFlow" ซึ่งเป็นแพลตฟอร์มจัดการสัญญาณไฟจราจรอัจฉริยะแบบไฮบริด ที่บูรณาการเทคโนโลยีการตรวจจับยานพาหนะเข้ากับอัลกอริทึม DRL ผ่านการทำงานร่วมกับโปรแกรม SUMO (Simulation of Urban MObility) พร้อมทั้งพัฒนาระบบส่วนติดต่อผู้ใช้งาน (Web Dashboard) เพื่อรองรับการควบคุมแบบครบวงจร โดยมีเป้าหมายหลักในการหาโมเดล AI ที่เหมาะสมที่สุดที่สามารถลดเวลารอคอยสะสม ลดความยาวของแถวคอย และเพิ่มขีดความสามารถในการระบายรถ เพื่อเป็นรากฐานสำคัญในการพัฒนาระบบการจราจรอัจฉริยะต่อไป

1.2 วัตถุประสงค์ของโครงการ

1. เพื่อพัฒนาระบบปัญญาประดิษฐ์โดยผ่านการใช้อัลกอริทึมการเรียนรู้แบบเสริมกำลังเชิงลึก (Deep Reinforcement Learning) ในการคำนวณและปรับเปลี่ยนระยะเวลาสัญญาณไฟจราจรอัตโนมัติ
2. เพื่อพัฒนาแพลตฟอร์มเว็บแอปพลิเคชันสำหรับการแสดงผลข้อมูลสถานะการจราจรและการทำงานของระบบแบบเรียลไทม์
3. เพื่อศึกษาและวิเคราะห์ผลกระทบของการนำระบบควบคุมสัญญาณไฟจราจรอัจฉริยะไปใช้งานในสภาพแวดล้อมจำลอง โดยวัดจากดัชนีชี้วัด เช่น เวลารอคอยสะสมเฉลี่ย ความยาวของแถวคอย และปริมาณการระบายรถ

1.3 ขอบเขตของโครงการ

1.3.1 ขอบเขตด้านการพัฒนาระบบ

1. ระบบประยุกต์ใช้โมเดล YOLOv12 ในการตรวจจับ จำแนก และนับจำนวนยานพาหนะบนท้องถนนจากภาพวิดีโอ
2. ระบบสามารถตัดสินใจปรับจังหวะและระยะเวลาของสัญญาณไฟจราจรได้โดยอัตโนมัติ อิงจากปริมาณรถที่ตรวจจับได้ โดยจำลองสภาพแวดล้อมการทำงานผ่านโปรแกรม SUMO ร่วมกับเทคนิคการเรียนรู้แบบเสริมกำลังเชิงลึก (Deep Reinforcement Learning)

3. มีการพัฒนาส่วนติดต่อผู้ใช้งานในรูปแบบเว็บแอปพลิเคชัน (Web Dashboard) เพื่อใช้แสดงผลข้อมูลภาพรวมแบบเรียลไทม์ เช่น ความหนาแน่นของการจราจร สถานะของสัญญาณไฟจราจร และข้อมูลสถิติต่าง ๆ ที่เกี่ยวข้อง

1.3.2 ขอบเขตด้านพื้นที่ศึกษา

การจำลองสภาพการจราจรและการควบคุมสัญญาณไฟจำกัดขอบเขตอยู่บนโครงข่ายถนนและทางแยกบริเวณเขตปทุมวัน (จำนวน 14 ทางแยก) ผ่านชุดข้อมูลแผนที่ในโปรแกรมจำลอง SUMO

1.3.3 ขอบเขตด้านกลุ่มผู้ใช้งานเป้าหมาย

1. ผู้ใช้งานทั่วไป: ประชาชนผู้ใช้รถใช้ถนนที่ต้องการตรวจสอบสภาพการจราจร ระดับความหนาแน่น และดูข้อมูลแบบเรียลไทม์ผ่านเว็บแอปพลิเคชัน เพื่อประกอบการตัดสินใจและวางแผนการเดินทาง
2. เจ้าหน้าที่ตำรวจจราจรหรือผู้ควบคุมสัญญาณไฟ: ที่ต้องการระบบช่วยเหลือในการตัดสินใจและสามารถควบคุมปรับจังหวะไฟจราจรเพื่อลดความแออัดแบบเรียลไทม์
3. หน่วยงานที่ตำรวจจราจรหรือผู้ควบคุมสัญญาณไฟ: ที่ต้องการเรียกดูสถิติ ข้อมูลภาพรวม และดัชนีความหนาแน่นของการจราจรผ่านเว็บแอปพลิเคชัน เพื่อนำไปใช้วางแผนแก้ไขปัญหาระยะยาว

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1. ได้องค์ความรู้เชิงเปรียบเทียบถึงประสิทธิภาพและข้อจำกัดของโมเดลการเรียนรู้แบบเสริมกำลัง (Reinforcement Learning) ในแต่ละรูปแบบ ซึ่งสามารถนำไปใช้เป็นแนวทางในการเลือกใช้โมเดลปัญญาประดิษฐ์ที่เหมาะสมที่สุดสำหรับการจัดการจราจร
2. สามารถลดระยะเวลาการรอคอยเฉลี่ยและบรรเทาปัญหาการสะสมของยานพาหนะบริเวณทางแยกได้อย่างมีประสิทธิภาพ ซึ่งช่วยเพิ่มสภาพคล่องทางการจราจรในภาพรวม
3. ได้แพลตฟอร์มส่วนกลางที่ช่วยอำนวยความสะดวกแก่เจ้าหน้าที่และหน่วยงานที่เกี่ยวข้องในการเฝ้าระวังสถานการณ์จราจรแบบเรียลไทม์ ซึ่งสามารถใช้เป็นต้นแบบในการประยุกต์ใช้ปัญญาประดิษฐ์เข้ากับระบบโครงสร้างพื้นฐาน เพื่อสนับสนุนการพัฒนาสู่การเป็นเมืองอัจฉริยะ (Smart City)

2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

การพัฒนา ระบบ TraffixFlow อาศัยการบูรณาการเทคโนโลยีขั้นสูงหลายแขนงเข้าด้วยกัน โดยมี ทฤษฎีและหลักการทำงานของเทคโนโลยีที่สำคัญ ดังนี้

2.1.1 คอมพิวเตอร์วิทัศน์ (Computer Vision) และการตรวจจับวัตถุ

คอมพิวเตอร์วิทัศน์เป็นศาสตร์แขนงหนึ่งของปัญญาประดิษฐ์ที่มุ่งเน้นให้คอมพิวเตอร์สามารถ ประมวลผล วิเคราะห์ และทำความเข้าใจข้อมูลจากภาพดิจิทัลหรือวิดีโอ ในโครงการนี้ได้ประยุกต์ใช้ อัลกอริทึมที่เกี่ยวข้องดังนี้:

- 1) YOLO (You Only Look Once): เป็นสถาปัตยกรรมโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) ที่ออกแบบมาเพื่อการตรวจจับวัตถุแบบเรียลไทม์ โครงการนี้เลือกใช้โมเดลรุ่นใหม่ล่าสุดอย่าง YOLOv12 ซึ่งมีความโดดเด่นด้านความเร็วในการอนุมานผล (Inference Speed) และความแม่นยำสูง สามารถระบุตำแหน่งของยานพาหนะพร้อมทั้งจำแนกประเภท (เช่น รถยนต์ รถจักรยานยนต์ รถบรรทุก) ได้ภายในขั้นตอนเดียว
- 2) DeepSORT (Deep Simple Online and Realtime Tracking): เป็นอัลกอริทึมสำหรับติดตามวัตถุ (Object Tracking) ที่ทำงานร่วมกับโมเดลตรวจจับวัตถุ โดยใช้การสกัดคุณลักษณะเชิงลึก (Deep Features) ของยานพาหนะแต่ละคัน ช่วยให้ระบบสามารถกำหนดรหัสประจำตัว (ID) ให้กับรถแต่ละคัน ป้องกันการนับรถซ้ำ และสามารถคำนวณปริมาณรถสะสมได้อย่างแม่นยำ

2.1.2 การเรียนรู้แบบเสริมกำลังเชิงลึก (Deep Reinforcement Learning: DRL)

การเรียนรู้แบบเสริมกำลังเชิงลึก เป็นแขนงหนึ่งของการเรียนรู้ของเครื่อง (Machine Learning) ที่นำโครงข่ายประสาทเทียมเชิงลึกมาประยุกต์ใช้เพื่อจำลองการเรียนรู้ของมนุษย์ผ่านการลองผิดลองถูก ประกอบด้วย "ตัวแทน (Agent)" ที่ทำหน้าที่ตัดสินใจเลือก "การกระทำ (Action)" ภายใต้ "สถานะ (State)"

ของ "สภาพแวดล้อม (Environment)" เพื่อให้ได้รับ "รางวัล (Reward)" สูงสุด โครงการนี้ได้นำ DRL มาใช้ควบคุมไฟจราจร โดยประเมินอัลกอริทึม 3 รูปแบบ ได้แก่:

- 1) DQN (Deep Q-Network): เป็นอัลกอริทึมที่ใช้โครงข่ายประสาทเทียมในการประมาณค่า Q-value (มูลค่าของการกระทำ) เหมาะสำหรับสภาพแวดล้อมที่มีพื้นที่การกระทำแบบไม่ต่อเนื่อง (Discrete Action Space) เช่น การเลือกสลับเฟสไฟจราจร
- 2) PPO (Proximal Policy Optimization): เป็นอัลกอริทึมประเภท Policy Gradient ที่ปรับปรุงนโยบาย (Policy) โดยตรง มีกลไกป้องกันไม่ให้นโยบายเปลี่ยนแปลงเร็วเกินไป ทำให้การเรียนรู้ของโมเดลมีความเสถียร (Stability) สูง และเป็นที่ยอมรับอย่างมากในปัจจุบัน
- 3) A2C (Advantage Actor-Critic): เป็นสถาปัตยกรรมแบบลูกผสม (Hybrid) ที่ประกอบด้วยเครือข่าย Actor (ผู้ตัดสินใจเลือกการกระทำ) และเครือข่าย Critic (ผู้ประเมินมูลค่าของการกระทำ) ทำให้โมเดลเรียนรู้ได้รวดเร็วและตอบสนองต่อสภาพการจราจรที่เปลี่ยนแปลงแบบพลวัตได้เป็นอย่างดี

2.1.3 แบบจำลองการจราจรระดับจุลภาค (Microscopic Traffic Simulation)

เนื่องจากการทดสอบระบบไฟจราจรในสภาพแวดล้อมจริงมีความเสี่ยงสูงและใช้ต้นทุนมหาศาล โครงการนี้จึงอาศัยโปรแกรมจำลองการทำงาน ดังนี้:

- 1) Eclipse SUMO (Simulation of Urban MObility): เป็นโปรแกรมจำลองการจราจรแบบโอเพ่นซอร์สที่สามารถจำลองการเคลื่อนที่ของยานพาหนะแต่ละคันได้อย่างละเอียด (Microscopic) ครอบคลุมถึงโครงข่ายถนนที่ซับซ้อน

TraCI (Traffic Control Interface): เป็นส่วนเชื่อมต่อ (API) ที่ทำหน้าที่เป็นตัวกลางระหว่างโปรแกรม SUMO และภาษา Python ช่วยให้โมเดลปัญญาประดิษฐ์สามารถดึงข้อมูลสถานะการจราจร (เช่น ความยาวแถวคอย เวลารอคอย) และส่งคำสั่งควบคุมสัญญาณไฟเข้าไปในแบบจำลองได้แบบเรียลไทม์

2.2 งานวิจัยที่เกี่ยวข้อง

ในการศึกษาและพัฒนาระบบควบคุมสัญญาณไฟจราจรอัจฉริยะ การทบทวนวรรณกรรมที่เกี่ยวข้องถือเป็นรากฐานสำคัญ การรับรู้สภาพการจราจรที่แม่นยำเป็นหัวใจของระบบอัจฉริยะ ในยุคแรก

ของการพัฒนาอัลกอริทึมเพื่อตรวจนับปริมาณรถบนถนนด้วยการประมวลผลภาพจากกล้องวิดีโอ มีการใช้เทคนิคพื้นฐาน เช่น การแยกพื้นหลัง (Mixture of Gaussians) ร่วมกับการวิเคราะห์blob (Blob Analysis) ซึ่งช่วยให้ระบบสามารถแยกแยะวัตถุที่เคลื่อนที่ได้อย่างแม่นยำด้วยต้นทุนที่ต่ำ [1]

ต่อมาเมื่อเทคโนโลยีพัฒนาสู่โครงข่ายประสาทเทียมเชิงลึก (Deep Learning) การประยุกต์ใช้คอมพิวเตอร์วิทัศน์ (Computer Vision) ได้รับการพัฒนาอย่างก้าวกระโดด มีการนำเสนอระบบจราจรอัจฉริยะที่ใช้โมเดล YOLOv8s วิเคราะห์ภาพจากกล้อง CCTV เพื่อประเมินความหนาแน่นของยานพาหนะและจัดสรรเวลาไฟเขียวแบบแปรผัน ซึ่งช่วยลดเวลารอคอยสะสมลงได้อย่างมาก [2] ในด้านความต้องการทรัพยากรการประมวลผล การประเมินประสิทธิภาพของโมเดล YOLOv10-nano พบว่ามีความเร็วในการอนุมานผลสูงและใช้ทรัพยากรต่ำ จึงเหมาะสำหรับการติดตั้งบนอุปกรณ์ปลายทาง (Edge devices) [3] สำหรับสถานะที่มีข้อจำกัดทางทัศนวิสัย การพัฒนาระบบนับยานพาหนะเวลากลางคืนด้วยโมเดล YOLOX ร่วมกับระบบติดตามวัตถุ ByteTrack และเทคนิคเครือข่ายปฏิปักษ์ทั่วไป (GANs) ช่วยให้โมเดลมีความแม่นยำในการตรวจจับสูงขึ้นอย่างเป็นรูปธรรม [4] การประมวลผลภาพยังถูกนำไปรวมกับการเรียนรู้ของเครื่อง (Machine Learning) เพื่อยกระดับระบบควบคุมการจราจร ดังเช่นการใช้แบบจำลอง YOLOv3 ร่วมกับอัลกอริทึมติดตามวัตถุ ที่ไม่เพียงแค่นับจำนวนยานพาหนะแต่ยังสามารถตรวจจับการขับซี้ผิดทิศทาง (Wrong-way driving) หรือการขับซี้ด้วยความประมาทได้อย่างแม่นยำสูง [5]

การเรียนรู้แบบเสริมกำลัง (Reinforcement Learning: RL) ได้กลายเป็นเทคโนโลยีหลักในการตัดสินใจควบคุมไฟจราจร การพัฒนาเข้าสู่ยุค Deep Reinforcement Learning (DRL) ทำให้เกิดโมเดล Deep Q-Network Traffic Signal Control Agent (DQTSCA) ที่เสนอรูปแบบการเก็บสถานะแบบ Discrete Traffic State Encoding (DTSE) เพื่อวิเคราะห์ข้อมูลตำแหน่งและความเร็วของรถอย่างละเอียด [6] สำหรับทางแยกที่ซับซ้อน โมเดล Double Dueling Deep Q Network (3DQN) ที่แบ่งพื้นที่ทางแยกเป็นตาราง (Grids) เพื่อกำหนดสถานะและใช้ผลต่างของเวลารอคอยสะสมเป็นฟังก์ชันรางวัล สามารถเรียนรู้และลดเวลารอคอยได้อย่างมีประสิทธิภาพ [7] การขยายขีดความสามารถให้ระบบเชื่อมต่อกับอุปกรณ์ในยุค IoT นำไปสู่การพัฒนาอัลกอริทึม Advantage Actor-Critic (A2C) แบบ Multi-agent ร่วมกับข้อมูลจากเซนเซอร์ IoT ในการบริหารจัดการโครงข่ายหลายทางแยก ซึ่งสามารถปรับตัวตามพลวัตของการจราจรและลดเวลาการรอคอยได้อย่างยอดเยี่ยม [8]


การบูรณาการระบบตรวจจับภาพเข้ากับการตัดสินใจด้วย RL ถือเป็นจุดเปลี่ยนสำคัญของการวิจัย มีการพัฒนาระบบที่ใช้โมเดล YOLOv4 นับจำนวนรถเพื่อส่งข้อมูลสถานะเข้าสู่โปรแกรมจำลอง SUMO และใช้อัลกอริทึม Deep Q-Learning คำนวณระยะเวลาไฟจราจร ซึ่งสามารถปรับตัวตามสภาพจราจรได้เป็นอย่างดี [9] รวมถึงระบบจัดการจราจรแบบเรียลไทม์ที่ใช้โมเดล YOLOv8 ร่วมกับสถาปัตยกรรม DQN บนแพลตฟอร์ม Pygame เพื่อเรียนรู้และสลับจังหวะสัญญาณไฟ ซึ่งช่วยลดเวลารอคอยเฉลี่ยลงได้อย่างเป็นรูปธรรม [10]

การประเมินประสิทธิภาพในสภาพแวดล้อมเสมือนจริงได้รับการยกระดับด้วยแพลตฟอร์มการจำลองร่วม (Co-simulation framework) ระหว่างโปรแกรม CARLA และ SUMO ที่ใช้กล้องเสมือนตรวจจับรถด้วยโมเดล YOLO ส่งข้อมูลไปยังเอเจนต์ Multi-Agent Reinforcement Learning (MARL) ซึ่งพิสูจน์ให้เห็นว่าอัลกอริทึมมีความทนทานต่อความคลาดเคลื่อนของเซนเซอร์ภาพได้อย่างยอดเยี่ยม [11] ในด้านสถาปัตยกรรมการจำลอง แพลตฟอร์ม Traffic Control Interface (TraCI) ได้รับการพัฒนาให้เป็นตัวกลางที่อนุญาตให้โปรแกรมภายนอกส่งคำสั่งเข้าไปปรับเปลี่ยนพฤติกรรมใน SUMO ได้แบบเรียลไทม์ [12] ท้ายที่สุด การขยายผลสู่เครือข่ายทางแยกขนาดใหญ่มีการนำเสนอสถาปัตยกรรม MARLIN-ATSC ซึ่งเป็นการใช้ MARL ควบคุมสัญญาณไฟจราจรหลายทางแยกให้ทำงานประสานกัน เพื่อให้เกิดการระบายรถในระดับโครงข่ายถนนอย่างสมบูรณ์แบบ [13]

จากการทบทวนวรรณกรรมและงานวิจัยที่เกี่ยวข้องข้างต้น พบว่าแม้จะมีการประยุกต์ใช้โมเดลตรวจจับวัตถุร่วมกับการเรียนรู้แบบเสริมกำลังบ้างแล้ว แต่ส่วนใหญ่ยังคงใช้โมเดลรุ่นเก่า หรือจำลองการทำงานเพียงทางแยกเดียว ดังนั้น โครงการนี้จึงนำเสนอระบบ "TraffixFlow" ที่ก้าวข้ามข้อจำกัดเดิม โดยการบูรณาการโมเดลคอมพิวเตอร์วิทัศน์ที่ทันสมัยที่สุดอย่าง YOLOv12 เพื่อความแม่นยำสูงสุดแบบเรียลไทม์ พร้อมทั้งนำเสนอการเปรียบเทียบประสิทธิภาพของอัลกอริทึม DRL ขั้นสูงถึง 3 รูปแบบ ได้แก่ PPO, DQN และ A2C ภายใต้สภาพแวดล้อมจำลองโครงข่ายถนนขนาดใหญ่ (10 ทางแยกเขตปทุมวัน) ผ่านโปรแกรม SUMO เพื่อค้นหาโซลูชันที่มีประสิทธิภาพสูงสุดในการยกระดับโครงสร้างพื้นฐานสู่การเป็นเมืองอัจฉริยะอย่างเป็นรูปธรรม

3. วิธีการดำเนินการวิจัย

การพัฒนาบริหารจัดการสัญญาณไฟจราจรอัจฉริยะแบบปรับตัวได้ (TraffixFlow) เป็นการบูรณาการเทคโนโลยีคอมพิวเตอร์วิทัศน์เข้ากับการเรียนรู้แบบเสริมกำลังเชิงลึก เพื่อประเมินและควบคุมสภาพการจราจรแบบเรียลไทม์ ภายใต้สภาพแวดล้อมจำลองระดับจุลภาค โดยผู้วิจัยได้แบ่งขั้นตอนการดำเนินงานและการพัฒนาระบบออกเป็นส่วนตัว่าง ๆ เพื่อให้บรรลุตามวัตถุประสงค์ที่ตั้งไว้ ดังมีรายละเอียดต่อไปนี้



รูปภาพที่: 1 แผนภาพแสดงสถาปัตยกรรมภาพรวมของระบบ TraffixFlow

3.1 การเตรียมความพร้อมของระบบและการตั้งค่า (System Setup)

ในขั้นตอนแรกของการพัฒนาระบบ ผู้วิจัยได้ทำการเตรียมความพร้อมของโครงสร้างพื้นฐานทั้งในด้านข้อมูลและฐานข้อมูล เพื่อให้สอดคล้องกับสถาปัตยกรรมของระบบ TraffixFlow ดังนี้

3.1.1 การเตรียมข้อมูลเชิงพื้นที่ (Spatial Data)

ผู้วิจัยได้ดำเนินการเตรียมข้อมูลเชิงพื้นที่เพื่อสร้างสภาพแวดล้อมจำลองให้สอดคล้องกับสภาพกายภาพจริง โดยจัดเก็บข้อมูลในรูปแบบมาตรฐาน JSON ประกอบด้วยไฟล์ 'pathumwan_roads.json' และ 'pathumwan_traffic_profile.json' สำหรับระบุพิกัดของกล่องวงจรปิด โครงข่ายถนน และตำแหน่งของทางแยก เพื่อให้ระบบสามารถรับรู้สภาพแวดล้อมได้อย่างถูกต้อง นอกจากนี้ ผู้วิจัยได้นำเข้าข้อมูลโครงข่ายถนนที่แปลงจากแผนที่จริง (OpenStreetMap) ผ่านไฟล์ 'osm.net.xml' รวมถึงข้อมูลกำหนดเส้นทางการเคลื่อนที่ (Route Data) ที่จำแนกตามประเภทยานพาหนะ ได้แก่ รถยนต์นั่งส่วนบุคคล ('osm.passenger.rou.xml') รถโดยสารประจำทาง ('osm.bus.rou.xml') รถจักรยานยนต์

(`osm.motorcycle.rou.xml`) และรถบรรทุก (`osm.truck.rou.xml`) เข้าสู่โปรแกรม SUMO เพื่อสร้างสภาพแวดล้อมจำลองการจราจรระดับจุลภาคที่มีความสมจริงและสะท้อนพฤติกรรมการเดินทางในพื้นที่ศึกษาได้อย่างแม่นยำ

3.1.2 การตั้งค่าระบบ (System Configuration)

การตั้งค่าระบบเริ่มจากการกำหนดค่าพารามิเตอร์ส่วนกลางเพื่อให้สอดคล้องกับสภาพแวดล้อมของการทดสอบ โดยระบบถูกออกแบบให้รองรับการสลับโหมดการทำงานผ่านตัวแปรสภาพแวดล้อม (Environment Variables) เช่น `SYSTEM\_MODE=sim` สำหรับการจำลอง และ `SYSTEM\_MODE=real` สำหรับการใช้งานจริง พร้อมทั้งมีการจัดเก็บค่าการตั้งค่าระบบลงในตาราง `runtime\_config` เพื่อให้สามารถปรับเปลี่ยนได้แบบพลวัต ในกรณีที่ดำเนินการในโหมดใช้งานจริง ระบบจะทำการเชื่อมต่อผ่านโพรโทคอลสตรีมมิงวิดีโอ (RTSP) เพื่อดึงภาพเหตุการณ์จากกล้องวงจรปิดเข้าสู่ระบบ นอกจากนี้ เพื่อให้การประมวลผลมีประสิทธิภาพ ผู้วิจัยได้ออกแบบสถาปัตยกรรมการทำงานแบบคู่ขนาน (Threading) โดยกำหนดรอบเวลา (Cadence) ที่ชัดเจน ได้แก่ การดึงภาพจากกล้องที่ความถี่ 4 เฟรมต่อวินาที การประมวลผลกระแสแสง (Optical Flow) ที่ 2 เฟรมต่อวินาที และการรวบรวมข้อมูลสถิติ (Aggregation) ทุก ๆ 30 วินาที


3.1.3 การพัฒนาระบบฐานข้อมูล (Database Setup)

ระบบใช้สถาปัตยกรรมฐานข้อมูลแบบเชิงสัมพันธ์ (Relational Database) ในการจัดเก็บข้อมูล โดยเลือกใช้ระบบจัดการฐานข้อมูล PostgreSQL สำหรับระบบที่ใช้งานจริง (Production) และ SQLite สำหรับการพัฒนาระบบภายใน (Local Development) การจัดการฐานข้อมูลดำเนินการผ่านเทคนิคการเชื่อมโยงวัตถุเชิงสัมพันธ์ (ORM) ด้วยไลบรารี SQLAlchemy เมื่อเริ่มต้นการทำงาน ระบบจะสร้างเค้าโครงฐานข้อมูล (Schema) ซึ่งประกอบด้วยตารางข้อมูลหลักจำนวน 16 ตาราง แบ่งเป็นกลุ่มข้อมูลโครงสร้างทางกายภาพ ข้อมูลการตรวจวัด และข้อมูลการตัดสินใจของปัญญาประดิษฐ์ พร้อมกันนี้ระบบจะทำการบรรจุข้อมูลตั้งต้น (Auto-seed) ของโครงข่ายถนนเขตปทุมวันโดยอัตโนมัติ และมีกลไกซิงโครไนซ์ข้อมูลอุปกรณ์กล้องจากโครงข่ายจำลอง เพื่อให้ฐานข้อมูลเป็นปัจจุบัน นอกจากนี้ ยังมีการกำหนดนโยบายการรักษาข้อมูล (Data Retention Policy) เช่น การลบข้อมูลดิบที่เก่าเกิน 7 วันโดยอัตโนมัติ เพื่อลดภาระการ

ประมวลผล (Overhead) และทำให้ระบบมีเสถียรภาพพร้อมรองรับปริมาณข้อมูล (Throughput) จากการตรวจจับแบบเรียลไทม์ได้อย่างมีประสิทธิภาพ

3.2 การพัฒนาระบบตรวจจับยานพาหนะ (Computer Vision Pipeline)

ระบบตรวจจับยานพาหนะเป็นส่วนประกอบสำคัญที่ทำหน้าที่เสมือนเซนเซอร์รับรู้สภาพการจราจร โดยบูรณาการแบบจำลองปัญญาประดิษฐ์เข้ากับอัลกอริทึมติดตามวัตถุ ซึ่งมีการออกแบบสถาปัตยกรรมให้รองรับการทำงานแบบเรียลไทม์และมีกลไกสำรองเมื่อเกิดข้อผิดพลาด ดังมีขั้นตอนการทำงานต่อไปนี้



รูปภาพที่: 2 แผนผังขั้นตอนการทำงานของระบบตรวจจับและติดตามยานพาหนะ (Computer Vision Pipeline)

3.2.1 การเตรียมแบบจำลอง (Model Initialization)

ผู้วิจัยได้นำแบบจำลองโครงข่ายประสาทเทียมที่ผ่านการฝึกฝนล่วงหน้า (Pre-trained model) รุ่น YOLOv12 มาเป็นแกนหลักในการตรวจจับ โดยระบบถูกออกแบบให้มีการโหลดและเตรียมความพร้อมของแบบจำลอง (Prewarm) ไว้ในหน่วยความจำโดยอัตโนมัติเมื่อเริ่มต้นการทำงาน พร้อมทั้งกำหนด

ค่าพารามิเตอร์สำหรับการอนุมานผล (Inference Settings) ที่จำเป็น เช่น ค่าระดับความเชื่อมั่น (Confidence Threshold) และค่าความทับซ้อนของวัตถุ (IOU) เพื่อควบคุมความแม่นยำในการตรวจจับ

3.2.2 การอนุมานผลและการติดตามวัตถุ (Inference and Tracking)

กระบวนการทำงานเริ่มจากการดึงภาพเฟรม (Frame) จากกล้องวงจรปิดแบบวนซ้ำ ภาพดังกล่าวจะถูกส่งเข้าสู่กระบวนการอนุมานผลด้วยแบบจำลอง YOLOv12 เพื่อระบุพิกัดกรอบ (Bounding Box) และประเภทของยานพาหนะ จากนั้น ข้อมูลกรอบวัตถุจะถูกส่งต่อไปยังอัลกอริทึม DeepSORT เพื่อประเมินทิศทางและติดตามการเคลื่อนที่ของยานพาหนะแต่ละคันอย่างต่อเนื่อง กระบวนการนี้ช่วยให้ระบบสามารถคำนวณตัวชี้วัดสถิติที่สำคัญแบบเรียลไทม์ ได้แก่ ปริมาณยานพาหนะ (Vehicle Count) ความเร็วเฉลี่ย (Average Speed) และความหนาแน่นของการจราจร (Traffic Density)

3.2.3 การประมวลผลและจัดเก็บผลลัพธ์ (Data Processing and Storage)

ข้อมูลสถิติการจราจรที่ผ่านการคำนวณจะถูกสร้างเป็นรูปแบบวัตถุข้อมูล (Data Object) และถูกรวบรวมไว้ในหน่วยความจำชั่วคราว ก่อนที่ระบบจะทำการยืนยันการบันทึก (Commit) ลงสู่ตารางในฐานข้อมูลเป็นระยะ (ทุก ๆ 5-10 วินาที) การออกแบบในลักษณะนี้ช่วยลดความหนาแน่นและลดภาระการประมวลผล (Overhead) ของฐานข้อมูล ทำให้ระบบมีเสถียรภาพในการทำงานอย่างต่อเนื่อง

3.3 การออกแบบระบบควบคุมสัญญาณไฟจราจรด้วยการเรียนรู้เชิงเสริมกำลัง (Traffic Signal Control Design)

เพื่อเปลี่ยนผ่านจากระบบควบคุมสัญญาณไฟจราจรแบบตั้งเวลาตายตัว (Fixed-time Control) ไปสู่ระบบแบบปรับตัวได้ (Adaptive Traffic Signal Control) แพลตฟอร์ม TraffixFlow ได้บูรณาการเทคนิคการเรียนรู้แบบเสริมกำลังเชิงลึก (Deep Reinforcement Learning: DRL) เข้ามาเป็นกลไกหลักในการตัดสินใจ

โดยกระบวนการเรียนรู้และสั่งการจะทำงานร่วมกับโปรแกรมจำลองการจราจรระดับจุลภาค SUMO ผ่านส่วนเชื่อมต่อ TraCI (Traffic Control Interface) แบบเรียลไทม์ สถาปัตยกรรม

การเรียนรู้ของตัวแทน (Agent) ในการควบคุมสัญญาณไฟจราจรประกอบด้วย องค์ประกอบสำคัญ 3 ส่วนตามหลักการของ DRL ดังนี้

3.3.1 การกำหนดพื้นที่สถานะ (State Space Design)

สถานะ (State) คือข้อมูลสภาพแวดล้อมที่ตัวแทนได้รับเพื่อนำไปใช้ประมวลผลและตัดสินใจเลือกการกระทำที่เหมาะสมที่สุด ณ ช่วงเวลานั้น ๆ ระบบ TrafficFlow ดึงข้อมูลสถานะเชิงลึกจากโครงข่ายทางแยกผ่านโปรแกรม SUMO และการประมวลผลภาพวิดีโอ โดยกำหนดตัวแปรสถานะหลักประกอบด้วย:

1. ความยาวของแถวคอย (Queue Length):
ระยะแถวสะสมของยานพาหนะในแต่ละช่องจราจรที่กำลังจอดรอสัญญาณไฟ
2. เวลารอคอยสะสม (Cumulative Wait Time):
เวลารวมที่ยานพาหนะทุกคันในแนวนวเข้าสู่ทางแยก (Approach)
ต้องหยุดนิ่งเนื่องจากติดสัญญาณไฟแดง
3. ปริมาณและความหนาแน่นของยานพาหนะ (Vehicle Count and Density):
ข้อมูลที่สกัดได้จากระบบตรวจจับ YOLOV12 ร่วมกับอัลกอริทึมติดตามวัตถุ DeepSORT

3.3.2 การกำหนดพื้นที่การกระทำ (Action Space Design)

การกระทำ(Action)คือคำสั่งควบคุมที่ตัวแทนเลือกส่งกลับไปยังระบบสัญญาณไฟจราจรเพื่อปรับเปลี่ยนเฟสไฟ โครงงานนี้กำหนดพื้นที่การกระทำเป็นแบบไม่ต่อเนื่อง (Discrete Action Space) เพื่อความเหมาะสมในการควบคุมจังหวะสัญญาณไฟจราจร โดยตัวแทนสามารถเลือกการกระทำได้ดังนี้:

1. การสลับเฟสสัญญาณไฟ (Phase Switching):
การตัดสินใจเปลี่ยนเฟสสัญญาณไฟเขียวไปยังทิศทางหรือแนวช่องจราจรที่มีความต้องการสูงกว่า
2. การคงสถานะเฟสปัจจุบัน (Phase Duration Extension):
การขยายเวลาสัญญาณไฟเขียวออกไปในทิศทางปัจจุบัน

หากตรวจจับได้แล้วยังมีปริมาณระบายอย่างต่อเนื่อง เพื่อแก้ไขปัญหา

"การให้สัญญาณไฟเขียวอย่างสูญเปล่า" (Wasteful Green Light Problem)

3.3.3 การออกแบบฟังก์ชันผลตอบแทน (Reward Function)

ฟังก์ชันผลตอบแทนเป็นตัวกำหนดเป้าหมายให้ตัวแทน (Agent)

พยายามเรียนรู้เพื่อให้ได้รับรางวัลสูงสุด

เนื่องจากเป้าหมายหลักของระบบคือการเพิ่มขีดความสามารถในการระบายรถและลดปัญหาการสะสมของยานพาหนะ ฟังก์ชันผลตอบแทนในระบบ TrafficFlow จึงถูกออกแบบให้มีความครอบคลุมและซับซ้อน โดยพิจารณาทั้งผลตอบแทนเชิงบวกและบทลงโทษเชิงลบ (Penalty) ดังสมการต่อไปนี้:

$$\text{Reward} = (\alpha \cdot \text{Throughput}) + (\beta \cdot \text{AvgSpeed}) - (\gamma \cdot \text{WaitTime}) - (\delta \cdot \text{QueueLength}) - (\epsilon \cdot \text{PhaseSwitch}) - \text{EmergencyPenalty}$$

โดยที่ปัจจัยในการคำนวณประกอบด้วย:

- ปัจจัยเชิงบวก:
 - Throughput: ปริมาณยานพาหนะที่ผ่านโครงข่ายได้สำเร็จ
 - AvgSpeed: ความเร็วเฉลี่ยของยานพาหนะในระบบที่สะท้อนถึงสภาพคล่อง
- ปัจจัยเชิงลบ
 - WaitTime: เวลารอคอยสะสมของยานพาหนะ
 - QueueLength: ความยาวของแถวคอยที่รอสัญญาณไฟ
 - PhaseSwitch: การหักคะแนนเมื่อระบบตัดสินใจสลับเฟสไฟจราจร เพื่อป้องกันปัญหาไฟกะพริบหรือการสลับไฟบ่อยเกินไปจนรถเคลื่อนตัวไม่ได้
 - EmergencyPenalty: บทลงโทษขั้นรุนแรงในกรณีที่ตรวจพบว่ามียานพาหนะจอดติดสะสมเป็นเวลานานเกินกว่า 120 วินาที

3.3.4 การประเมินและคัดเลือกอัลกอริทึม (Algorithm Selection and Evaluation)

ตัวแทนในระบบ TrafficFlow ถูกฝึกสอนบนสภาพแวดล้อมโครงข่ายถนนขนาด 14 ทางแยก ด้วยอัลกอริทึม 3 รูปแบบ:

1. **DQN (Deep Q-Network):** ใช้โครงข่ายประสาทเทียมในการประมาณค่ามูลค่าของการกระทำ (Q-value) ซึ่งเหมาะสมกับพื้นที่การกระทำแบบไม่ต่อเนื่อง
 2. **PPO (Proximal Policy Optimization):** ปรับปรุงนโยบาย (Policy) โดยตรงและมีกลไกป้องกันไม่ให้นโยบายเปลี่ยนแปลงเร็วเกินไป ทำให้การเรียนรู้ของโมเดลมีความเสถียร (Stability) สูง
 3. **A2C (Advantage Actor-Critic):** สถาปัตยกรรมแบบลูกผสมที่ใช้เครือข่าย Actor ในการตัดสินใจเลือกการกระทำ และเครือข่าย Critic สำหรับประเมินมูลค่า ทำให้สามารถตอบสนองต่อสภาพการจราจรที่เปลี่ยนแปลงแบบพลวัตได้เป็นอย่างดี
- จากผลการทดลองเปรียบเทียบกับระบบตั้งเวลาตายตัวที่เป็นเส้นฐาน (Baseline) พบว่าอัลกอริทึม A2C มีประสิทธิภาพสูงที่สุดในทุกดัชนีชี้วัด โดยสามารถทำคะแนนผลตอบแทนเฉลี่ยได้สูงสุดที่ 402.62 สามารถเพิ่มปริมาณการระบายรถสะสมได้ร้อยละ 12.75 และลดเวลารอคอยสะสมลงเหลือ 8,698 วินาที หรือลดลงร้อยละ 36.36

3.4 การพัฒนาเว็บแอปพลิเคชันและส่วนแสดงผลข้อมูลแบบเรียลไทม์ (Web Application and Real-time Dashboard Development)

การพัฒนาเว็บแอปพลิเคชันสำหรับแพลตฟอร์ม TrafficFlow มีวัตถุประสงค์หลักเพื่อควบคุมและแสดงผลข้อมูลสถานะการจราจร รวมถึงการทำงานของระบบควบคุมไฟจราจรอัจฉริยะแบบเรียลไทม์ โดยสถาปัตยกรรมถูกออกแบบให้รองรับกลุ่มผู้ใช้งานที่หลากหลาย ทั้งประชาชนทั่วไป เจ้าหน้าที่ตำรวจจราจร และหน่วยงานวางแผนนโยบาย แพลตฟอร์มนี้แบ่งการพัฒนาออกเป็น 3 ส่วนหลัก ดังนี้:

3.4.1 สถาปัตยกรรมเครือข่ายและระบบหลังบ้าน (Backend Architecture & API Development)

ระบบหลังบ้านทำหน้าที่เป็นศูนย์กลางในการประมวลผล รับส่งข้อมูล และเชื่อมโยงส่วนประกอบทั้งหมดของ TraffixFlow เข้าด้วยกัน โดยถูกพัฒนาด้วย Python โดยใช้เฟรมเวิร์ก Flask เพื่อรองรับการทำงานแบบไม่พร้อมกัน (Asynchronous I/O) ซึ่งช่วยให้ระบบสามารถจัดการคำขอเชื่อมต่อพร้อมกันได้ในปริมาณมาก (High Concurrency) ได้อย่างมีประสิทธิภาพ

1. **การเชื่อมต่อสภาพแวดล้อมจำลอง:** ระบบหลังบ้านเชื่อมต่อกับโปรแกรมจำลองการจราจร SUMO ผ่านการส่งการของภาษา Python เพื่อดึงค่าตัวชี้วัดประสิทธิภาพจากเอเจนต์ปัญญาประดิษฐ์ (A2C) แบบเรียลไทม์
2. **การสื่อสารแบบเรียลไทม์ (Real-time Communication):**
ข้อมูลความหนาแน่นและสถานะเฟสไฟจราจรจะถูกส่งต่อไปยังส่วนหน้าบ้าน (Frontend) ทันทีผ่านโปรโตคอล WebSockets (Socket.io) เพื่อลดการหน่วงของข้อมูลและหลีกเลี่ยงการดึงข้อมูลแบบซ้ำ ๆ ที่ไม่จำเป็น (Polling)

3.4.2 การออกแบบส่วนติดต่อผู้ใช้งาน (Frontend & User Interface Design)

ส่วนหน้าบ้านถูกพัฒนาในรูปแบบ Web Dashboard ที่เน้นความสลับคล่องและการตอบสนองอย่างรวดเร็ว (Responsive Design) เพื่อรองรับการเข้าใช้งานผ่านอุปกรณ์ที่หลากหลาย โดยแบ่งหน้าจอการแสดงผลตามสิทธิ์ของผู้ใช้งาน:

1. **ระบบแสดงผลสำหรับผู้ใช้งานทั่วไป (Public View):**
แสดงแผนที่โครงข่ายถนนเขตปทุมวันพร้อมรหัสสีจำแนกความหนาแน่นของการจราจร (เช่น เขียว เหลือง แดง) เพื่อช่วยในการวางแผนเดินทาง
2. **ระบบควบคุมสำหรับผู้เจ้าหน้าที่ (Operator/Police Dashboard):**
เจ้าหน้าที่สามารถเฝ้าระวังสถานการณ์ภาพรวม ดูภาพสตรีมมิงจากกล้อง RTSP ที่ซ้อนทับกรอบวัตถุ (Bounding Box) จาก YOLOv12 ได้ พร้อมทั้งมีอินเทอร์เฟซแสดงผลสถานะสัญญาณไฟเขียว-ไฟแดงในแต่ละทิศทาง และปุ่มสั่งการสำหรับปรับเปลี่ยนจากการควบคุมด้วย AI กลับมาเป็นโหมดควบคุมด้วยมือ (Manual Override) ในกรณีฉุกเฉิน

3. ระบบวิเคราะห์สถิติสำหรับเจ้าหน้าที่ (Analytical View): ส่วนแสดงผลกราฟและแผนภูมิเชิงสถิติ (Data Visualization) นำเสนอดัชนีชี้วัดประสิทธิภาพ ได้แก่ ปริมาณการระบายรถสะสมเฉลี่ย (Average Throughput) และเวลารอคอยสะสมเฉลี่ย (Average Wait Time) ในรูปแบบรายชั่วโมงหรือรายวัน เพื่อนำข้อมูลไปใช้วางแผนแก้ไขปัญหาจราจรในระยะยาว

3.4 การพัฒนาเว็บแอปพลิเคชันและส่วนแสดงผลข้อมูลแบบเรียลไทม์ (Web Application and Real-time Dashboard Development)

การพัฒนาเว็บแอปพลิเคชันสำหรับแพลตฟอร์ม TraffixFlow มีวัตถุประสงค์หลักเพื่อควบคุมและแสดงผลข้อมูลสถานะการจราจร รวมถึงการทำงานของระบบควบคุมไฟจราจรอัจฉริยะแบบเรียลไทม์ โดยสถาปัตยกรรมถูกออกแบบให้รองรับกลุ่มผู้ใช้งานที่หลากหลาย ทั้งประชาชนทั่วไป เจ้าหน้าที่ตำรวจจราจร และหน่วยงานวางแผนนโยบาย แพลตฟอร์มนี้แบ่งการพัฒนาออกเป็น 3 ส่วนหลัก ดังนี้:

3.4.1 สถาปัตยกรรมเครือข่ายและระบบหลังบ้าน (Backend Architecture & API Development)

ระบบหลังบ้านทำหน้าที่เป็นศูนย์กลางในการประมวลผล รับส่งข้อมูล และเชื่อมโยงส่วนประกอบทั้งหมดของ TraffixFlow เข้าด้วยกัน โดยถูกพัฒนาด้วยภาษา Python โดยใช้เฟรมเวิร์ก Flask เพื่อรองรับการทำงานแบบไม่พร้อมกัน (Asynchronous I/O) ซึ่งช่วยให้ระบบสามารถจัดการคำขอเชื่อมต่อพร้อมกันได้ในปริมาณมาก (High Concurrency) ได้อย่างมีประสิทธิภาพ

1. การเชื่อมต่อสภาพแวดล้อมจำลอง: ระบบหลังบ้านเชื่อมต่อกับโปรแกรมจำลองการจราจร SUMO ผ่านการส่งการของภาษา Python เพื่อดึงค่าตัวชี้วัดประสิทธิภาพจากเอเจนต์ปัญญาประดิษฐ์ (A2C) แบบเรียลไทม์
2. การสื่อสารแบบเรียลไทม์ (Real-time Communication): ข้อมูลความหนาแน่นและสถานะไฟจราจรจะถูกส่งต่อไปยังส่วนหน้าบ้าน (Frontend) ทันทีผ่านโปรโตคอล WebSockets (Socket.io) เพื่อลดการหน่วงของข้อมูลและหลีกเลี่ยงการดึงข้อมูลแบบซ้ำ ๆ ที่ไม่จำเป็น (Polling)

การออกแบบส่วนติดต่อผู้ใช้งาน (Frontend & User Interface Design)

ส่วนหน้าบ้านถูกพัฒนาในรูปแบบ Web Dashboard ที่เน้นความลื่นไหลและการตอบสนองอย่างรวดเร็ว (Responsive Design) เพื่อรองรับการเข้าใช้งานผ่านอุปกรณ์ที่หลากหลาย โดยแบ่งหน้าจอการแสดงผลตามสิทธิ์ของผู้ใช้งาน:

1. ระบบแสดงผลสำหรับผู้ใช้งานทั่วไป (Public View):

แสดงแผนที่โครงข่ายถนนเขตปทุมวันพร้อมรหัสสีจำแนกความหนาแน่นของการจราจร (เช่น เขียว เหลือง แดง) เพื่อช่วยในการวางแผนเดินทาง

2. ระบบควบคุมสำหรับเจ้าหน้าที่ (Operator/Police Dashboard):

เจ้าหน้าที่สามารถเฝ้าระวังสถานการณ์ภาพรวม ดูภาพสตรีมมิงจากกล้อง RTSP ที่ซ้อนทับกรอบวัตถุ (Bounding Box) จาก YOLOv12 ได้ พร้อมทั้งมีอินเทอร์เฟซแสดงผลสถานะสัญญาณไฟเขียว-ไฟแดงในแต่ละทิศทาง และปุ่มสั่งการสำหรับปรับเปลี่ยนจากการควบคุมด้วย AI กลับมาเป็นโหมดควบคุมด้วยมือ (Manual Override) ในกรณีฉุกเฉิน

3. ระบบวิเคราะห์สถิติสำหรับเจ้าหน้าที่ (Analytical View):

ส่วนแสดงผลกราฟและแผนภูมิเชิงสถิติ (Data Visualization) นำเสนอดัชนีชี้วัดประสิทธิภาพ ได้แก่ ปริมาณการระบายรถสะสมเฉลี่ย (Average Throughput) และเวลารอคอยสะสมเฉลี่ย (Average Wait Time) ในรูปแบบรายชั่วโมงหรือรายวัน เพื่อนำข้อมูลไปใช้วางแผนแก้ไขปัญหาจราจรในระยะยาว

4. ผลการวิจัยและอภิปรายผล

การศึกษารายงานวิจัยโครงงานเรื่อง การพัฒนาระบบจัดการสัญญาณไฟจราจรอัจฉริยะแบบปรับตัวได้ (TraffixFlow) มีวัตถุประสงค์เพื่อพัฒนาระบบควบคุมสัญญาณไฟจราจรที่สามารถประเมินและตอบสนองต่อสภาพการจราจรได้แบบเรียลไทม์ ผ่านการบูรณาการเทคโนโลยีคอมพิวเตอร์วิทัศน์ (Computer Vision) และการเรียนรู้แบบเสริมกำลังเชิงลึก (Deep Reinforcement Learning: DRL) โดยในบทนี้ ผู้วิจัยจะนำเสนอผลการดำเนินงาน ผลการทดสอบประสิทธิภาพของแบบจำลอง และการอภิปรายผลการวิจัย ซึ่งแบ่งหัวข้อการนำเสนอออกเป็น 4 ส่วนหลัก ดังต่อไปนี้

4.1 ผลการพัฒนาระบบส่วนต่อประสานกับผู้ใช้งาน (Web Application & User Interface)

จากการดำเนินงาน ผู้วิจัยได้พัฒนาระบบ TraffixFlow และเว็บแอปพลิเคชัน (Web Dashboard) สำหรับผู้ดูแลระบบสำเร็จตามสถาปัตยกรรมที่ออกแบบไว้ โดยระบบสามารถเชื่อมต่อและแสดงผลข้อมูลการจราจรแบบเรียลไทม์ได้ดังนี้

4.1.1 หน้ากระดานควบคุมหลัก (Main Dashboard)

ระบบสามารถแสดงภาพรวมของโครงข่ายถนนเขตปทุมวันทั้ง 14 ทางแยก โดยมีการแสดงแผนที่เชิงโต้ตอบ (Interactive Map) และกราฟแสดงดัชนีจราจร (Traffic Index) แบบเรียลไทม์

(คำแนะนำ: แอปภาพหน้าจอเว็บเพจหน้า Dashboard หลักของคุณมาแปะตรงนี้ พร้อมใส่คำบรรยายได้ภาพ เช่น "รูปภาพที่ X แสดงหน้ากระดานควบคุมหลักของระบบ TraffixFlow")

4.1.2 หน้าแสดงผลสตรีมมิงวิดีโอ (Video Streaming Page)

ระบบสามารถดึงภาพจากกล้อง CCTV เสมือน และแสดงผลการทำงานของระบบแบบเรียลไทม์ (คำแนะนำ: แอปภาพหน้าจอเว็บเพจหน้าที่แสดงกล้อง CCTV หรือการตั้งค่ากล้องมาแปะตรงนี้)

4.2 ผลการทดสอบประสิทธิภาพของระบบตรวจจับยานพาหนะ (Computer Vision Performance)

ผลการทดสอบการทำงานของไปป์ไลน์คอมพิวเตอร์วิทัศน์ พบว่าแบบจำลอง YOLOv12 สามารถตรวจจับและจำแนกประเภทยานพาหนะได้อย่างแม่นยำ และเมื่อทำงานร่วมกับอัลกอริทึม DeepSORT ระบบสามารถติดตามการเคลื่อนที่ (Tracking) และกำหนดรหัสประจำตัว (ID) ให้กับยานพาหนะแต่ละคันได้อย่างมีประสิทธิภาพ ส่งผลให้การคำนวณปริมาณรถสะสมมีความคลาดเคลื่อนต่ำ

(คำแนะนำ: แปะรูปภาพจากโปรเจกต์ของคุณ ที่เป็นภาพรถบนถนนและมีกรอบสี่เหลี่ยม (Bounding Box) ดีล้อมรอบรถ พร้อมตัวเลข ID ของรถ)

4.3 ผลการทดสอบประสิทธิภาพของระบบควบคุมสัญญาณไฟด้วย AI (DRL Performance)

ผู้วิจัยได้ดำเนินการประเมินประสิทธิภาพของระบบควบคุมสัญญาณไฟจราจร โดยเปรียบเทียบอัลกอริทึม DRL 3 รูปแบบ ได้แก่ PPO, DQN และ A2C โดยใช้ระบบควบคุมสัญญาณไฟแบบกำหนดเวลาตายตัว (Fixed-time Control) เป็นเส้นฐาน (Baseline) ผลการทดสอบมีรายละเอียดดังนี้

(คำแนะนำ: สร้างตารางสรุปตัวเลข 4 คอลัมน์ (อัลกอริทึม | ผลตอบแทน | ระบายรถ (คัน) | เวลารอ (วินาที)) และไว้ตรงนี้)

4.3.1 ผลการเปรียบเทียบคะแนนผลตอบแทนเฉลี่ย (Average Reward)

จากการจำลองการเรียนรู้ พบว่าอัลกอริทึม A2C สามารถบรรจบเข้าสู่จุดที่เหมาะสมที่สุด (Convergence) ได้อย่างมีประสิทธิภาพและทำคะแนนผลตอบแทนเฉลี่ยได้สูงสุดที่ 402.62 คะแนน ซึ่งแสดงให้เห็นว่ากลไก Actor-Critic สามารถเรียนรู้นโยบายสลับจังหวะสัญญาณไฟได้อย่างมีประสิทธิภาพสูงสุด เมื่อเทียบกับ PPO และ DQN

4.3.2 ผลการเปรียบเทียบปริมาณการระบายรถสะสมเฉลี่ย (Average Throughput)

ระบบ TrafficFlow ที่ควบคุมด้วยอัลกอริทึม A2C สามารถเพิ่มปริมาณการระบายรถสะสมได้สูงถึง 3,749 คัน หรือคิดเป็นอัตราการระบายรถที่เพิ่มขึ้นร้อยละ 12.75 เมื่อเทียบกับระบบตั้งเวลาตายตัว

4.3.3 ผลการเปรียบเทียบเวลารอคอยสะสมเฉลี่ย (Average Wait Time)

เมื่อเปลี่ยนมาใช้ในการควบคุมด้วยอัลกอริทึม A2C ระบบสามารถปรับจังหวะไฟให้สอดคล้องกับปริมาณรถแบบพลวัต ส่งผลให้เวลารอคอยสะสมเฉลี่ยในโครงข่ายลดลงเหลือเพียง 8,698 วินาที หรือคิดเป็นการลดลงอย่างมีนัยสำคัญถึงร้อยละ 36.36 เมื่อเปรียบเทียบกับเส้นฐาน

4.4 การอภิปรายผลการวิจัย (Discussion)

จากผลการทดลองทั้งหมด สามารถอภิปรายผลได้ว่า การบูรณาการคอมพิวเตอร์วิทัศน์เข้ากับการเรียนรู้แบบเสริมกำลังเชิงลึก (DRL) เป็นแนวทางที่มีศักยภาพสูงในการแก้ปัญหาการจราจรติดขัด อัลกอริทึม A2C มีความเหมาะสมอย่างยิ่งสำหรับโครงข่ายถนนเขตปทุมวันที่มีความซับซ้อนและมีจุดตัดทางแยกจำนวนมาก เนื่องจากสถาปัตยกรรมแบบ Hybrid ของ A2C ช่วยให้ตัวแทนสามารถตอบสนองต่อการเปลี่ยนแปลงของปริมาณรถกะทันหันได้ดีกว่าอัลกอริทึมอื่น

อย่างไรก็ตาม แม้ว่าระบบ TrafficFlow จะแสดงผลลัพธ์ที่ยอดเยี่ยม แต่แบบจำลองที่ฝึกสอนในโครงข่ายนี้มีการเรียนรู้และปรับตัวให้เข้ากับลักษณะทางกายภาพที่อ้างอิงจากข้อมูลของเขตปทุมวันเป็นหลัก (Overfitting to Environment) ดังนั้น หากต้องการนำระบบไปติดตั้งในโครงข่ายถนนพื้นที่อื่น อาจส่งผลให้ประสิทธิภาพการ

ทำงานลดลง จึงมีความจำเป็นที่จะต้องนำแบบจำลองไปทำการฝึกสอนเพิ่มเติม (Fine-tuning) ให้มีความหลากหลายมากขึ้นในงานวิจัยระยะต่อไป

7. เอกสารอ้างอิง

- [1] ชลธิศา เวทโอสถ และ นิคม สุวรรณวร, "การพัฒนาอัลกอริทึมเพื่อตรวจนับปริมาณรถบนถนนด้วยการประมวลผลภาพจากกล้องวิดีโอ," *Princess of Naradhiwas University Journal*, vol. 5, no. 1, 2556.
- [2] O. A. Abiamamela and R. V. Samuel, "Computer Vision for Intelligent Traffic Monitoring and Control," *IRE Journals*, vol. 8, no. 5, 2024.
- [3] I. Kutika, V. Lahimade, T. Todingan, S. R. Sentinuwo, and M. D. Putro, "Real-time Vehicle Detection using YOLOv10-nano Algorithm for Monitoring Traffic Analysis," *Jurnal Teknik Elektro dan Komputer*, vol. 14, no. 2, pp. 1-6, 2025.
- [4] พสธร พลอยแก้ว, "ระบบการนับยานพาหนะแยกตามประเภทสำหรับวิดีโอที่บันทึกจราจรเวลากลางคืน" (วิทยานิพนธ์มหาบัณฑิต), จุฬาลงกรณ์มหาวิทยาลัย, 2566.
- [5] H. Khan and J. S. Thakur, "Smart traffic control: machine learning for dynamic road traffic management in urban environments," *Multimedia Tools and Applications*, vol. 84, pp. 10321-10345, 2025.
- [6] W. Genders and S. Razavi, "Using a Deep Reinforcement Learning Agent for Traffic Signal Control," *arXiv preprint arXiv:1611.01142*, 2016.
- [7] X. Liang, X. Du, G. Wang, and Z. Han, "Deep Reinforcement Learning for Traffic Light Control in Vehicular Networks," *IEEE Transactions on Vehicular Technology*, 2018.
- [8] S. Damadam, M. Zourbakhsh, R. Javidan, and A. Faroughi, "An Intelligent IoT Based Traffic Light Management System: Deep Reinforcement Learning," *Smart Cities*, vol. 5, no. 4, pp. 1293-1311, 2022.
- [9] M. Sahal, Z. Hidayat, Y. Bilfaqih, M. A. Hady, and Y. M. H. Tampubolon, "Smart Traffic Light Using YOLO Based Camera with Deep Reinforcement Learning Algorithm," *Journal on Advanced Research in Electrical Engineering*, vol. 7, no. 1, 2023.

- [10] R. R. Raj, R. Shanker, and M. Maranco, "Dynamic AI Traffic Signal System for Real-Time Traffic Management Using Pygame and YOLO V8," *ICRDICCT*, 2025.
- [11] T. Azfar and R. Ke, "Traffic Co-Simulation Framework Empowered by Infrastructure Camera Sensing and Reinforcement Learning," *arXiv preprint arXiv:2412.03925*, 2024.
- [12] A. Wegener, M. Piórkowski, M. Raya, H. Hellbrück, S. Fischer, and J. P. Hubaux, "TraCI: An Interface for Coupling Road Traffic and Network Simulators," *Proceedings of the 11th Communications and Networking Simulation Symposium (CNS '08)*, pp. 155-163, 2008.
- [13] S. El-Tantawy, B. Abdulhai, and H. Abdelgawad, "Multiagent Reinforcement Learning for Integrated Network of Adaptive Traffic Signal Controllers (MARLIN-ATSC): Methodology and Large-Scale Application on Downtown Toronto," *IEEE Transactions on Intelligent Transportation Systems*, vol. 14, no. 3, 2013.
- [14] T. Horsuwan and C. Aswakul, "Reinforcement Learning Agent under Partial Observability for Traffic Light Control in Presence of Gridlocks," in *SUMO User Conference 2019 (EpiC Series in Computing, vol. 62)*, 2019, pp. 29-47.